Departamento de Matemáticas y Física
Guía de Aprendizaje: Laboratorio de Modelado de Datos

DATOS GENERALES

Asignatura:	**Laboratorio de Modelado de Datos**			**Créditos BCD:**	**4 horas por semana**
Clave:	**ITE3657**	**Grupo:**		**Créditos TIE:**	
Horario:	**Martes y Viernes 13:00 – 15:00**	**Carreras:**	**Ingeniería y Ciencia de Datos**	**Salón:**	**Virtual**
Departamento:	**Matemáticas y Física**	**UAB:**	**Matemáticas para Finanzas y Economía**	**Periodo:**	**Otoño 2024**
Coordinador UAB:	**Juan Diego Sánchez Torres**		**E-mail:**	**dsanchez@iteso.mx**	**Ext. 3069**
Profesor:	**Sara Eugenia Rodríguez Reyes**		**E-mail:**	**cd682324@iteso.mx**	

BCD: *Bajo Conducción Docente* TIE: *Trabajo Independiente del Estudiante*

PRESENTACIÓN

En la realización de un modelo basado en datos es importante tener en cuenta que el éxito del modelo está asociado a la calidad de los datos que se estén utilizando. Es importante realizar el preprocesamiento de los datos para construir un modelo usando los mismos. Una vez desarrollados los modelos es necesario evaluar su validez, por medio de mediciones y evaluaciones de datos desconocidos de prueba.

En este curso se prepararán datos y se construirán modelos predictivos, los cuales serán validados por medio de métricas de error y criterios de aceptación. Además, se abordará la construcción de los modelos y fundamentarlos por medio de la comunicación de resultados, evaluación de pronósticos del modelo y la metodología establecida para la preparación de los datos.

Para cursar esta asignatura se requieren haber aprobado el laboratorio de procesamiento de datos y el laboratorio de visualización de datos.

CONTEXTUALIZACIÓN DE LA ASIGNATURA

Para tener un desempeño satisfactorio de esta asignatura es indispensable contar con conocimientos de programación, cálculo diferencial y estadística. Es deseable manejar algún lenguaje científico de programación, por ejemplo, MatLab, R, Python.

Al finalizar con éxito la asignatura se tendrán las herramientas básicas para la limpieza, visualización de datos provenientes de diversas fuentes de información y el uso de métodos de modelado y predicción para la obtención de conocimiento de datos provenientes de distintos ámbitos.

PROPÓSITO GENERAL

Dado un conjunto de datos preparado, evaluar modelos de aprendizaje automático para seleccionar el que dé la mejor solución a un problema de clasificación o regresión.

PROPÓSITOS TRANSVERSALES

a) Colaborar con los compañeros de clase.
b) Generar el hábito de resolver problemas con herramientas computacionales.
c) Usar de manera efectiva y eficaz las tecnologías de información para representar e interpretar los conceptos en diferentes formas: numérica, geométrica, algebraica y algorítmica.
d) Implementar en Python los conocimientos adquiridos en este curso.

ACTITUDES Y VALORES

Se espera que al cursar esta asignatura se desarrolle responsabilidad ante la actividad académica, manifiesta en al menos los siguientes aspectos:

- ❑ Participación activa, con compromiso, perseverancia y actitud positiva.
- ❑ El cumplimiento de las normas de disciplina establecidas.
- ❑ El cumplimiento en tiempo y forma de las actividades que se encomienden como trabajo independiente.
- ❑ El desarrollo de espíritu crítico y autocrítico (constructivo) en el análisis del desempeño propio y de los compañeros.
- ❑ El sentido de la ética, evitando, en particular, cometer actos deshonestos en la realización de las actividades evaluativas.
- ❑ El desarrollo de la capacidad para identificar características personales al afrontar procesos de aprendizaje y, como consecuencia, para aprender con mayor independencia.
- ❑ Diálogo abierto, directo y respetuoso tanto con el profesor como con los compañeros.
- ❑ Tolerancia y respeto

PROPÓSITOS ESPECÍFICOS

- Importar bases de datos provenientes de fuentes públicas
- Seleccionar variables relevantes de una base de datos mediante el análisis estadístico de las mismas
- Calcular parámetros estadísticos para describir la estructura de los datos
- Visualizar información con la ayuda de gráficos y tablas
- Clasificar datos por medio de algoritmos de clustering, regresión y clasificación supervisada.

EVALUACIÓN DEL APRENDIZAJE

Productos	% de Calificación
Reportes de prácticas de laboratorio (Portafolio)	20
Tareas y Exámenes	40
Proyecto: • Reporte • Presentación oral	40 30 10
TOTAL:	**100%**

Temario

1. **Tipos de técnicas de modelado**
1.1. Lenguajes de programación para el modelado
1.2. Proceso de Ciencia de Datos
1.3. Repositorios de datos
1.4. Tipos de procesos de aprendizaje
1.5. Tipos de modelos de datos
1.6. Tipos de datos
1.7. Procesamiento de datos
1.8. Técnicas de selección de variables
1.9. Técnicas de reducción de dimensionalidad
2. **Diseño de pruebas**
2.1. Selección de datos de entrenamiento
2.2. Selección de datos de prueba
2.3. Validación cruzada
3. **Clustering**
3.1. Kmeans
3.2. Jerárquico
4. **Regresión**
4.1.1. Regresión lineal simple y múltiple
4.1.2. Redes neuronales
4.1.3. Máquina de vectores soporte
4.1.4. Árboles de decisión
4.1.5. Bosques aleatorios
5. **Clasificación**
5.1.1. Regresión logística
5.1.2. Máquina de vectores soporte
5.1.3. Arboles de decisión
5.1.4. Arboles aleatorios
5.1.5. Redes neuronales
6. **Evaluación del modelo**
6.1. Matriz de confusión
6.2. Índices de desempeño para clasificación
6.3. Índices de desempeño para regresión
7. **Series de Tiempo (Extra)**
8. **Presentación oral de resultados usando las técnicas de narrativas (storytelling)**

Políticas y lineamientos del curso.

- El inicio de toma de asistencia es 10 minutos después de la hora. Por ejemplo, si el horario de clases es de 7:00 a 9:00 el profesor podrá tomar asistencia a las 7:10. Para los alumnos que lleguen después de tomar lista no existen retardos y a criterio del profesor podrán entrar al salón de clases.
- Los alumnos tendrán que esperar al profesor hasta por 20 minutos, después de ese tiempo se podrán ir sin falta. En la siguiente clase el profesor indicará la fecha de reposición de la clase o de los minutos por su retraso. En las clases de reposición no se toma asistencia.
- Habrá exámenes para hacer en casa, los cuales se dará la notificación con una semana de anticipación.
- Habrá un proyecto de aplicación de los alumnos que entregarán con su respectivo reporte.
- Se realizarán prácticas en el laboratorio para manejo de datos y obtención de resultados.
- Todas las prácticas serán realizadas en el software Python.
- Dentro de clase no se permite hacer uso de celulares.

- El pase de lista se hará en cada clase al inicio de la sesión.
- Todas las tareas serán entregadas por medio de la plataforma CANVAS y no se recibirán tareas a destiempo.
- No se recibirán tareas tiempo después de la fecha límite; aunque se solicite que sea considerada con una calificación menor (Sean cuidadosos con la organización de sus tiempos y cuidar los tiempos de entrega).
- En clase no se permite hacer desorden que afecte la impartición de la clase. De hacerlo, el alumno tendrá que abandonar la sesión de clase.
- La calificación aprobatoria es mayor o igual a 6.0 sin aplicar criterios de redondeo si se encuentra por debajo de este límite.
- Se permite como máximo el 20% de inasistencias al curso, equivalente a 6 inasistencias para mantener el derecho a calificación. El mostrar evidencia de enfermedad, actividades deportivas no elimina la falta. Se necesita una asistencia de por lo menos del 60% para tener derecho a extraordinario.
- El alumno que copie o deje copiar/plagiar exámenes o trabajos se sancionará con "CERO".
- Tareas y trabajos son necesarios entregarlos oportunamente en la plataforma para tener derecho a calificación. No se aceptan trabajos, tareas o avances del trabajo final fuera de fechas.
- No hay exentos, todos presentan proyecto final.
- Es obligación del alumno presentarse el día y hora fijada para la entrega de la evaluación final del curso, teniendo el derecho a pedir, en ese momento, aclaraciones sobre su evaluación. En caso de no asistir pierde su derecho a cualquier reclamación.
- Si requiere aclaración sobre la calificación final, debe estar fundamentada de acuerdo con los criterios de calificación descritos en el programa.

REFERENCIAS BIBLIOGRÁFICAS Y TELEMÁTICAS:

FUENTES REQUERIDAS

- Data Science for Business: What You Need to Know about Data Mining and Data-Analytic, Provost, F. y Fawcett, T., O'Reilly Media, 2013, ISBN: 978-1-449-37428-0 978-1-449-37429-7
- Foundations of Statistical Algorithms: with Reference to R Packages, Weihs, C. Mersmann, O. y Ligges, U., CRC Press, 2014, ISBN: 978-1-4398-7885-9.
- An Introduction to Machine Learning, Kubat, M., Springer, 2015, ISBN: 978-3-319-20009-5.
- Predictive Analytics with Microsoft Azure Machine Learning; Roger Barga, Valentine Fontama, Wee Hyong Tok, 2015, ISBN: 978-1-4842-1201-1
- Python Business Intelligence Cookbook; R. Dempsey, 2015, ISBN: 978-1-78528-966-8.
- An Introduction to Statistical Learning: with Applications in R. Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani. Editor Springer, 2013. ISBN 1461471370, 978-1461471370
- Hands-On Big Data Modeling: Effective database design techniques for data architects and business intelligence professionals. Autores James Lee, Tao Wei, Suresh Kumar Mukhiya Editor Packt. Publishing Ltd, 2018. ISBN 1788626087, 9781788626088

FUENTES DE APOYO

- El profesor proporcionará documentos de estudio con información relevante conforme el curso se vaya llevando a cabo. Este material se compartirá con los alumnos.