TALLER DE MODELADO DE DATOS

Mtra. Sara Eugenia Rodríguez Reyes

TÉCNICAS MULTIVARIADAS

SELECCIÓN DE VARIABLES

Razones Fundamentales

- Dimensionalidad y Complejidad
- Reducción de Ruido y Mejora de Precisión
- Evitar el overfitting
- Interpretabilidad del modelo
- Eficiencia Computacional

Selección de variables ≠ Reducción Dimensionalidad

Selección de variables

Selecciona características para mantener o eliminar del conjunto de datos.

Reducción Dimensionalidad

- Crea una proyección de datos que da como resultado características completamente nuevas.
- Es una alternativa a la selección de variables.

Técnicas de Selección de Variables

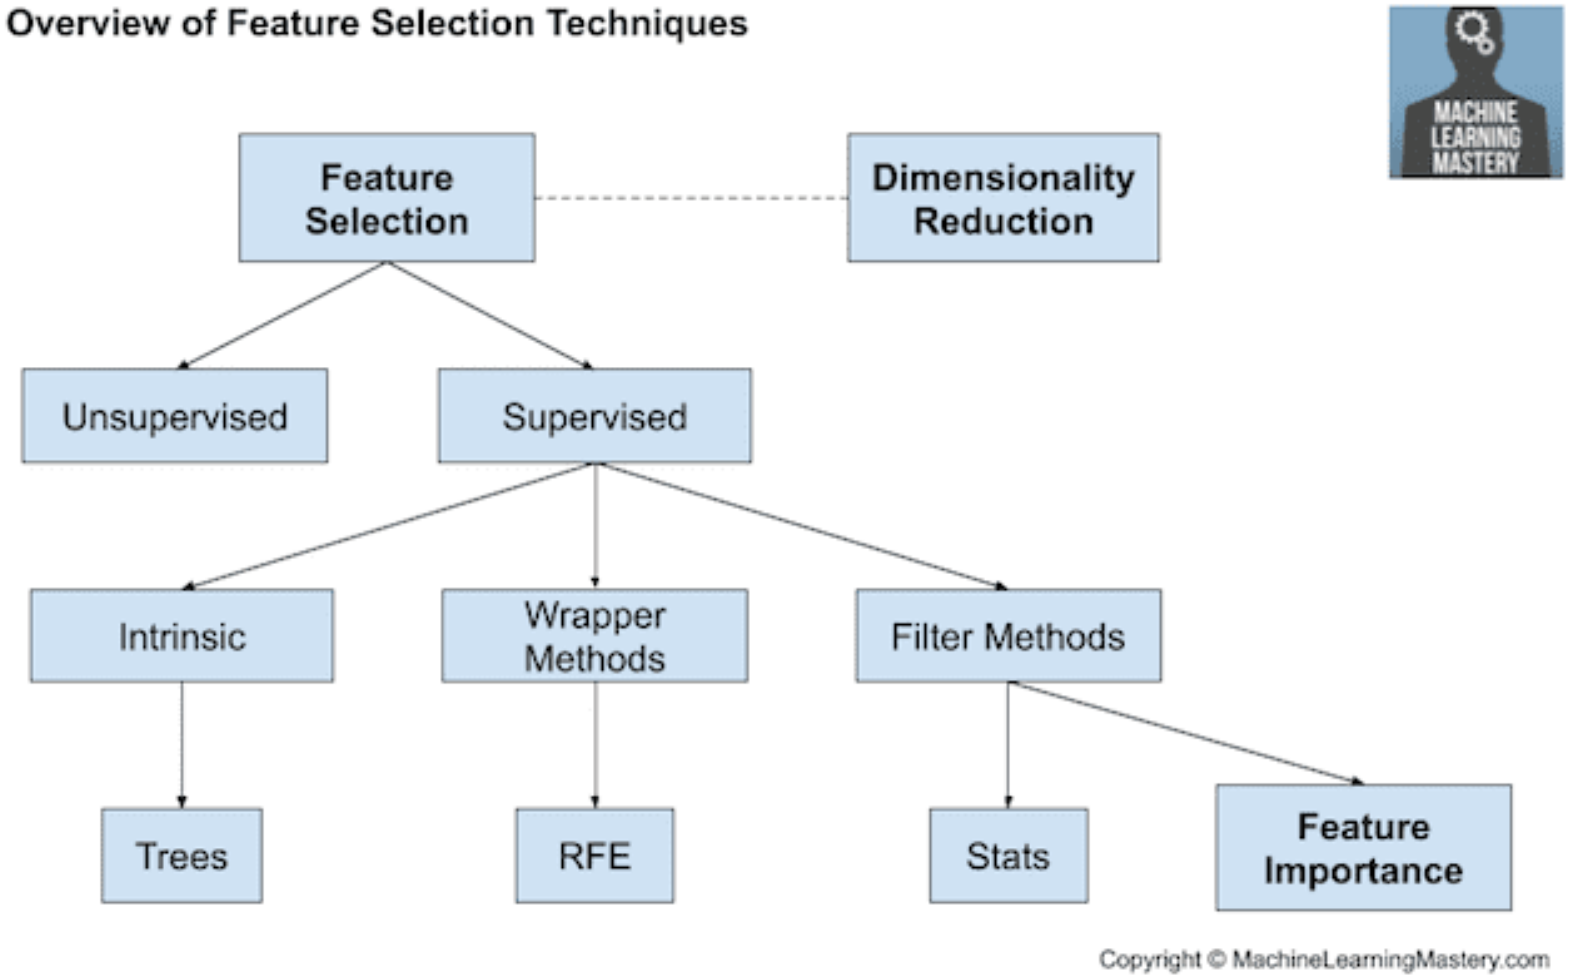

Métodos de Filtrado

- Es muy común utilizar medidas estadísticas de tipo “correlación” entre variables de entrada y salida como base para la selección de variables.
- La elección de medidas estadísticas depende en gran medida de los tipos de datos

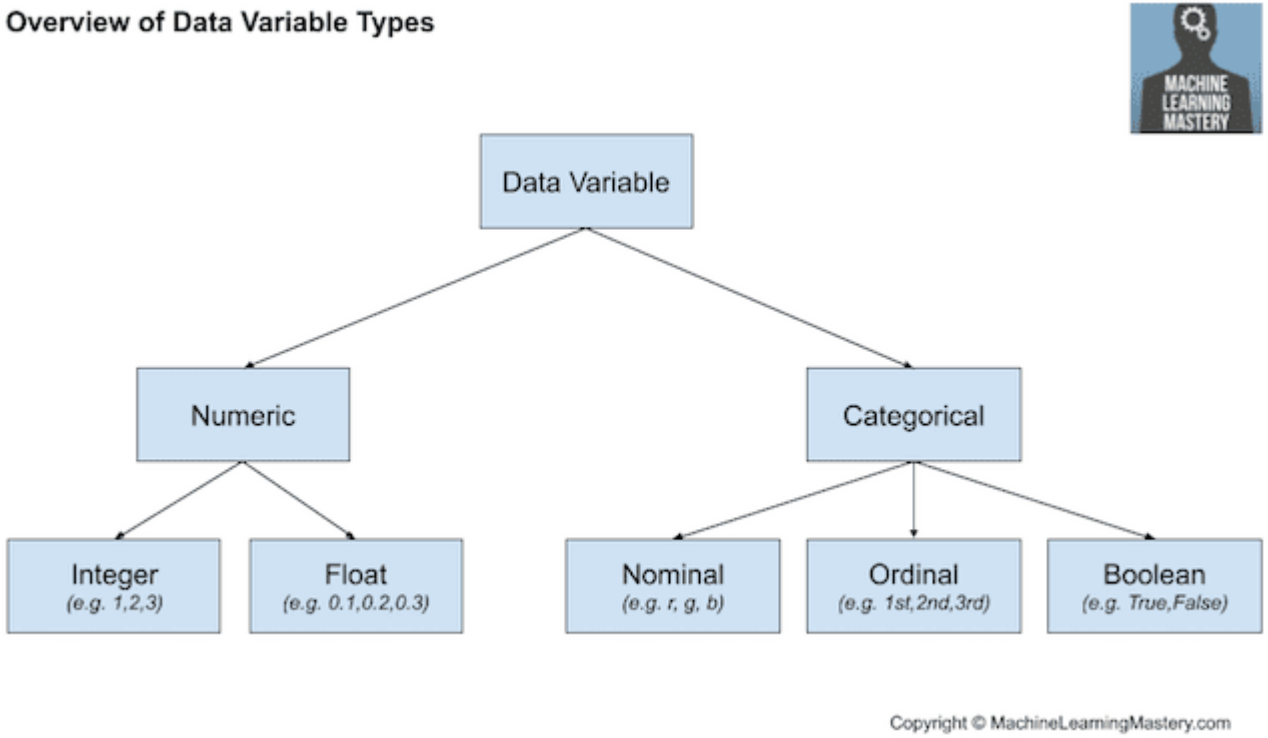

Cómo seleccionar el método

- Es muy común utilizar medidas estadísticas de tipo “correlación” entre variables de entrada y salida como base para la selección de variables.
- La elección de medidas estadísticas depende en gran medida de los tipos de datos

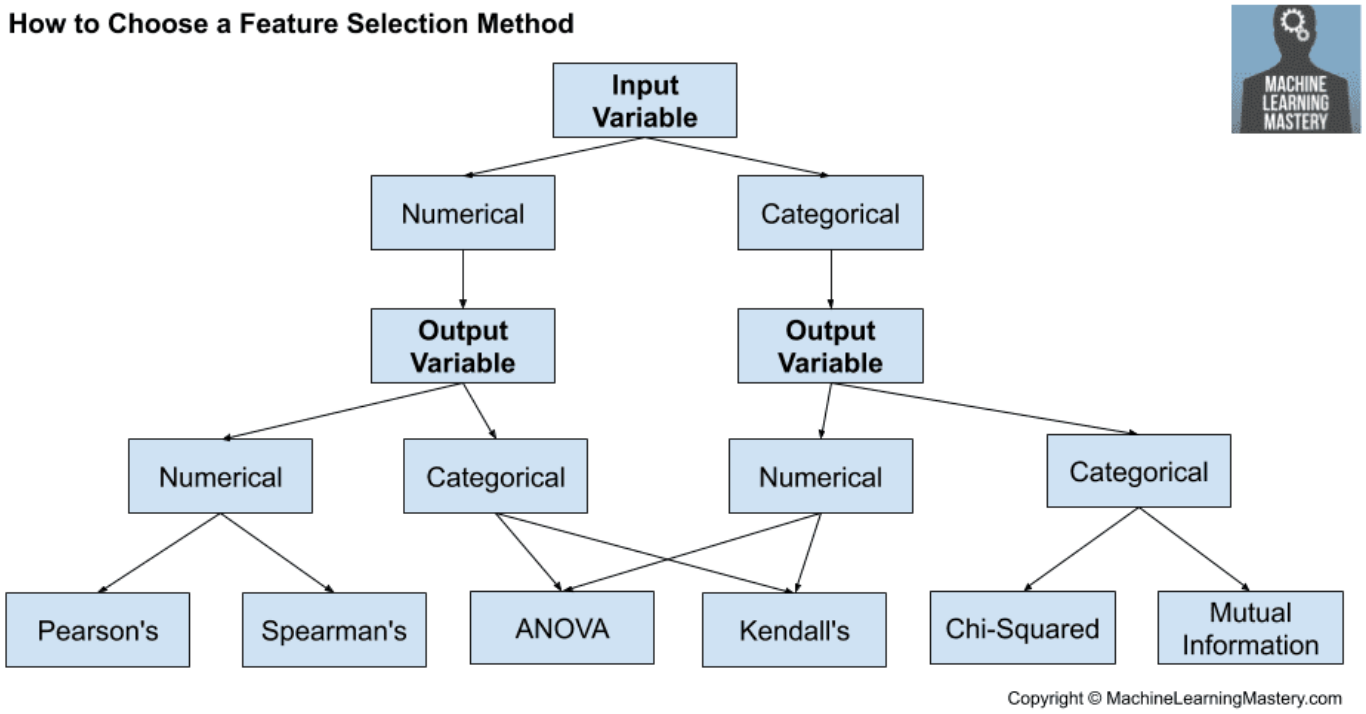

Algunos tips en python

- Estadísticas de correlación: la librería de scikit-learn provee ya la implementación de las medidas estadísticas más útiles, por ejemplo:
  - Coeficiente de correlación de Pearson: f_regression()
  - ANOVA: f_classif()
  - Chi-cuadrada: chi2()
  - Información mutua: mutual_info_classif() y mutual_info_regression()

- Selección del método: scikit-learn también proporciona muchos métodos de filtrado una vez que se han calculado las estadísticas para cada variable de entrada con el objetivo.

Métodos Wrapper

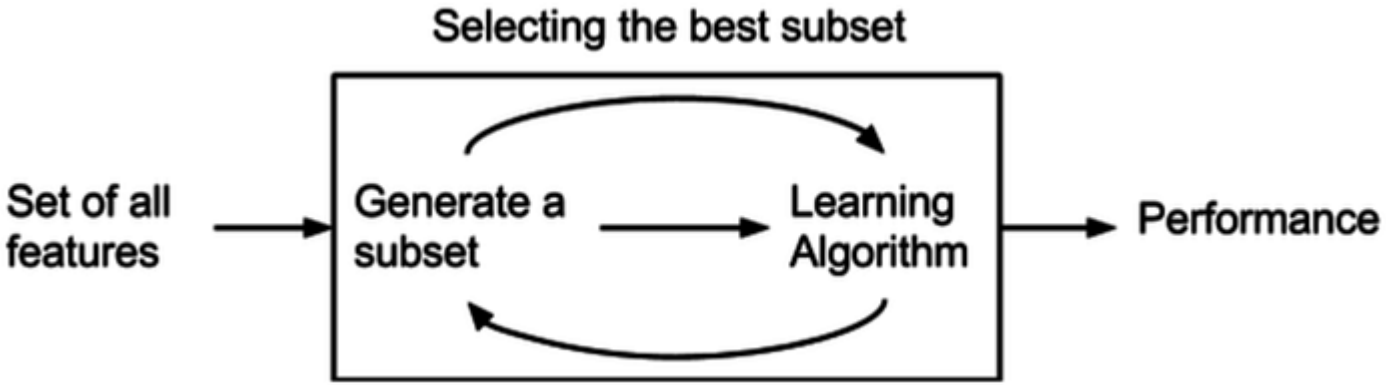

- Tratan a la selección de variables como un problema de búsqueda.
- Evalúan diferentes subconjuntos de variables y miden su impacto en el performance del modelo de machine learning específico.

Estrategias comunes:

- Forward Selection
- Backward Elimination:
- Recursive Feature Elimination

Ventajas y consideraciones:

Ventajas

- Optimización específica del modelo
- Efectivo para modelos complejos
- Interacción de variables
- Garantía de buscar el mejor performance

Consideraciones

- Costo computacional
- Riesgo de sobre-ajuste
- Elección del modelo
- Calidad de los datos

Métodos Embebidos

- Combinan las ventajas de los métodos de filtrado y los métodos de envoltura

- Los métodos wrapper consideran variables sin importancia de forma iterativa en función de la métrica de evaluación, mientras que los métodos embebidos realizan la selección de variables y el entrenamiento del algoritmo en paralelo.

- La ventaja de estos métodos es que son más continuos en el proceso y no sufren de tanta variabilidad

LASSO

- Es un método de reducción que realiza tanto la selección de variables como la regularización al mismo tiempo.

- La regularización es un proceso que reduce los coeficientes (pesos) hacia cero. Significa que estás penalizando modelos más complejos para evitar el sobreajuste.

- LASSO permite que los coeficientes se establezcan en 0. Si un coeficiente es cero, entonces la característica no se toma en cuenta y, por lo tanto, en cierto modo se descarta.

$$L_{lasso}(\hat{\beta}) = \sum_{i=1}^{n}(y_i - x_i'\hat{\beta})^2 + \lambda \sum_{j=1}^{m}|\hat{\beta}_j|.$$

Feature Importance

- Los métodos más conocidos son los basados en árboles.
- La mayoría utiliza el Gini index (reducción promedio de la impureza) para estimar la importancia de cada variable, mientras más pequeño el valor, más importante es la variable.

$$Gini = 1 - \sum_{i=1}^{n} (P_i)^2$$

¿Cuál es el mejor método?

- No hay....

- Toca descubrir qué funciona mejor para el problema específico mediante una experimentación cuidadosa y sistemática.

Ejercicio en python